

Fichas Descriptivas de los Estudios Incluidos en la Revisión Sistemática

Autora:	Jackeline Bermeo Pacheco
Institución:	Universidad de Cuenca
Fecha:	Junio del 2025
Versión:	En revisión
Tipo de documento:	Anexo complementario (Fichas de análisis de estudios incluidos)
Contenido:	<p>Este documento presenta las fichas técnicas y analíticas correspondientes a los estudios seleccionados en la revisión sistemática mencionada. Cada ficha incluye información clave del estudio, como:</p> <ul style="list-style-type: none">● Título completo● Autores y año de publicación● DOI o enlace al estudio● Clasificación temática● Resumen estructurado● Puntos clave del aporte metodológico o funcional● Cobertura de dimensiones analizadas (detección, predicción, comparación, almacenamiento, contextualización, visualización)

El objetivo de este documento es proporcionar una visión clara, sistemática y comparativa de los estudios incluidos, sirviendo como material de referencia para futuras investigaciones y para la validación del proceso de análisis realizado en el artículo principal.

Fichas Descriptivas de los Estudios Incluidos en la Revisión Sistemática	1
1: Anomaly Detection in Univariate Time-Series: A Survey on the State-of-the-Art	3
2 : Anomaly Detection in Univariate Time Series Using a Multi-Criteria Approach	4
3 : Context-aware Domain Adaptation for Time Series Anomaly Detection	5
4 : Sintel: A Machine Learning Framework to Extract Insights from Signals	6
5 : Open Challenges in Time Series Anomaly Detection: An Industry Perspective	7
6 : A Systematic Review of Anomaly Detection Using Machine and Deep Learning Techniques	9
7 : On the Nature and Types of Anomalies: A Review of Deviations in Data	10
8 : On Data Efficiency of Univariate Time Series Anomaly Detection Models	11
9 : Lag Selection for Univariate Time Series Forecasting Using Deep Learning: An Empirical Study	12
10 : Context Discovery for Anomaly Detection	13
11 : Neural Contextual Anomaly Detection for Time Series	14
12: A Systematic Review of Anomaly Detection within High Dimensional and Multivariate Data	15
13: A Review on Outlier/Anomaly Detection in Time Series Data	16
14 : New Trends in Time Series Anomaly Detection	18
15: A Systematic Literature Review of Time Series Methods Applied to Epidemic Prediction	19
16: Deep Learning for Time Series Anomaly Detection: A Survey	20
17 Título: Dive into Time-Series Anomaly Detection: A Decade Review	21
18 : Time Series Forecasting using Artificial Neural Networks Methodologies: A Systematic Review	22
19: Enhancing Time Series Anomaly Detection: A Knowledge Distillation Approach with Image Transformation	23
20 : TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data	25
21 : Deep Learning for Anomaly Detection: A Survey	26
22: Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy	27
23 : TadGAN: Time Series Anomaly Detection Using Generative Adversarial Networks	29
24 : Reward Once, Penalize Once: Rectifying Time Series Anomaly Detection	30
25 : PeFAD: A Parameter-Efficient Federated Framework for Time Series Anomaly Detection	32
26 : MTV: Visual Analytics for Detecting, Investigating, and Annotating Anomalies in Multivariate Time Series	33

1: Anomaly Detection in Univariate Time-Series: A Survey on the State-of-the-Art

- Autores: Mohammad Braei, Dr.-Ing. Sebastian Wagner
- Año: 2020
- DOI: arxiv.org/abs/2004.00433
- Clasificación temática: Revisión no sistemática, detección de anomalías, evaluación comparativa de modelos
- Resumen: Revisión no sistemática sobre técnicas de detección de anomalías en series temporales univariantes. Clasifica 20 métodos en categorías estadísticas, aprendizaje automático y redes neuronales. Evalúa anomalías puntuales, colectivas y contextuales, reporta métricas AUC y tiempos de cómputo.
- Puntos clave:
 - Clasificación: estadísticas, ML, redes neuronales
 - Tipos de anomalías: puntuales, colectivas, contextuales
 - Datasets: NYCT, Yahoo
 - Métricas: ARIMA (AUC 0.906), AR (0.902), LSTM (0.84)
 - No aborda almacenamiento ni contextualización
 - Revisión no sistemática de 20 métodos para detectar anomalías en series univariantes.

Criterio	Valor	Observaciones
Año	2020	
Tipo de estudio	Revisión no sistemática	
Naturaleza	Teórica	
Incluye framework	No	
Framework diseño propio	No	
Uso de datos reales	No	Es revision
Validación en entornos reales	No	
Revisión por pares	Sí	Publicado en Data Science and Engineering (Springer)
Código disponible	No	
Detección de anomalías	Sí	Revisión sobre métodos existentes
Predicción	Parcial	Se mencionan métodos con predicción, pero no se aplica ni evalúa directamente
Almacenamiento	No	
Comparación entre eventos	No	No hay evidencia de comparación entre eventos anómalos dentro de la misma serie. El trabajo se enfoca en revisión de métodos de detección, sin análisis específico entre eventos.
Considera contexto externo	No	

Visualización avanzada	No	Solo diagramas conceptuales básicos
------------------------	----	-------------------------------------

2 : Anomaly Detection in Univariate Time Series Using a Multi-Criteria Approach

- Autor: Maciej Wolny
- Año: 2024
- DOI: 10.29119/1641-3466.2024.213.46
- Clasificación temática: Detección de anomalías, framework, comparación
- Resumen: El artículo propone un enfoque multicriterio para la detección de anomalías en series temporales univariantes. La metodología incluye la construcción de residuos mediante modelado estadístico, detección de outliers por umbrales y agregación de decisiones bajo tres reglas: restrictiva, liberal y por puntuación. Usa datos simulados y se centra en cómo distintas combinaciones de criterios afectan la sensibilidad del sistema, sin validar en contextos reales ni utilizar datasets públicos. No propone un sistema software ni visualizaciones complejas.
- Puntos clave:
 - Framework en cinco etapas: modelado, residuos, detección, agregación
 - Uso de datos simulados
 - No aborda contextualización ni almacenamiento
 - Sin validación en entornos reales
- Observaciones: comparación intraserie: Compara salidas de varios métodos internos dentro del propio framework (residuos + reglas), aunque no compara modelos externos ni detecciones de anomalías específicas.

Criterio	Valor	Observaciones
Año	2024	
Tipo de estudio	Estudio de investigación técnica	
Naturaleza	Teórico	
Incluye framework	Si	
Framework propuesto	Sí	Propone un marco multi-criterio
Uso de datos reales	No	Datos sintéticos
Validación en entornos reales	No	
Revisión por pares	Sí	
Código disponible	No	
Detección de anomalías	Sí	Objetivo principal del estudio
Predicción	No	
Almacenamiento	No	
Comparación entre eventos	Parcial	Se identifican referencias a métricas de comportamiento y patrones, con algunas

		comparaciones entre observaciones, aunque no desarrolladas profundamente..
Considera contexto externo	No	
Visualización avanzada	Sí	Gráficos básicos

3 : Context-aware Domain Adaptation for Time Series Anomaly Detection

- Autores: Kwei-Herng Lai, Lan Wang, Huiyuan Chen, et al.
- Año: 2023
- DOI: N/A
- Clasificación temática: Detección de anomalías, contextualización externa
- Resumen: Framework para detectar anomalías en series temporales multivariantes mediante adaptación de dominio. Integra información contextual (como tipo de máquina, entorno o ubicación) como datos de entrada auxiliares para mejorar la generalización entre dominios heterogéneos. Evalúa el rendimiento del modelo en datasets como SMD, MSL, SMAP y Boiler, demostrando mejoras significativas frente a modelos base. No ofrece software, ni propone almacenamiento ni visualización avanzada de los resultados.
- Puntos clave:
 - Usa datos de SMD, Boiler, MSL, SMAP
 - Contextualización con datos de origen
 - Mejora generalización en dominios heterogéneos
 - No incluye almacenamiento ni visualización
- Observaciones: Contexto externo Parcial: Se asigna "Parcial" cuando el estudio utiliza variables auxiliares o metadatos que no forman parte directa de la serie temporal, pero provienen del mismo sistema o dataset, sin incorporar información del mundo real externo (como clima, salud, economía, etc.)

Criterio	Valor	Observaciones
Autor	Lai et al.	-
Año	2023	
Tipo de estudio	Estudio aplicado	Propone un modelo propio y lo valida experimentalmente en datasets reales.
Naturaleza	práctico	
Incluye framework	Sí	Presenta el modelo ContextTDA, con arquitectura modular.
Framework diseño propio	Sí	El framework es diseñado completamente por los autores, no adaptado.
Uso de datos reales	Sí	Usa datasets reales (MSL, SMAP, SMD), aunque obtenidos de repositorios públicos.
Validación en entornos reales	Parcial	Los datos son reales pero la validación se realiza en entornos controlados (no producción real).
Revisión por pares	Sí	Publicado en una conferencia indexada con peer-review.

Código disponible	Parcial	Enlace disponible: https://github.com/laiyyy/ContextTDA Usa scripts y repositorios públicos para preprocesamiento (e.g., OmniAnomaly para SMD, SMAP, MSL; repositorio de SASA para Boiler), no se indica el código de Context TDA
Detección de anomalías	Sí	Es la tarea principal del modelo.
Predicción	Sí	Utiliza un autoencoder LSTM para predecir valores esperados y calcular errores de reconstrucción, que se combinan con puntuaciones de clasificación para detectar anomalías.
Almacenamiento	No	No aborda cómo almacenar anomalías ni estructuras de gestión.
Comparación entre eventos	No	El enfoque está en adaptación de modelos a nuevas condiciones, pero no se identifican comparaciones directas entre anomalías en la misma serie.
Considera contexto externo	Parcial	Utiliza datos de un dominio fuente (serie diferente) como contexto para mejorar la detección en otro dominio.
Visualización avanzada	No	Solo Muestran resultados gráficos y curvas ROC, pero no hay visualización herramientas.

4 : Sintel: A Machine Learning Framework to Extract Insights from Signals

- Autores: Sarah Alnegheimish, Dongyu Liu, Carles Sala, et al.
- Año: 2022
- DOI: 10.1145/3514221.3517910
- Clasificación temática: Framework integral, detección, visualización
- Resumen: Sistema modular para detectar, visualizar y comparar anomalías en series multivariantes. Permite anotaciones colaborativas y benchmarking.
- Puntos clave:
 - Almacena datos y metadatos en MongoDB
 - Pipelines automáticos (ARIMA, LSTM, Autoencoders)
 - Interfaces gráficas interactivas
 - No enfocado en univariantes

Criterio	Valor	Observaciones
Autor	Alnegheimish et al.	-
Año	2022	Confirmado en la publicación.
Tipo de estudio	Estudio aplicado	Se propone y valida un framework propio usando múltiples datasets.
Naturaleza	práctico	

Incluye framework	Sí	El framework completo se llama Sintel y se describe en detalle.
Framework diseño propio	Sí	Sintel es una arquitectura creada por los autores, no adaptada de otro modelo.
Uso de datos reales	Sí	Se usan datos reales (señales de radar, telemetría, etc.) de diferentes dominios.
Validación en entornos reales	Parcial	Aunque usa datos reales, las pruebas se realizan en entornos simulados o de laboratorio, no sistemas en producción.
Revisión por pares	Sí	Publicado en IEEE Access, una revista con revisión por pares.
Código disponible	Sí	Proporcionan repositorio en GitHub: https://github.com/dynamo-lab/sintel
Detección de anomalías	Sí	Es uno de los objetivos del framework (junto con clasificación y segmentación).
Predicción	Parcial	Los pipelines (e.g., LSTM DT, LSTM AE, TadGAN) predicen señales esperadas o reconstruyen datos para calcular discrepancias (errores) que identifican anomalías.
Almacenamiento	Si	Incluye una base de datos MongoDB para almacenar señales, anomalías detectadas, anotaciones humanas y resultados de experimentos, creando una base de conocimiento persistente.
Comparación entre eventos	No	Aunque trabaja con múltiples series y modelos, no realiza comparación directa entre eventos dentro de una misma serie temporal.
Considera contexto externo	No	El análisis se basa solo en las señales propias, no incorpora variables externas como clima, ubicación, etc.
Visualización avanzada	Sí	Incluye dashboards y representación visual interactiva de resultados, uno de los aspectos destacados del framework.

5 : Open Challenges in Time Series Anomaly Detection: An Industry Perspective

- Autor: Andreas C. Müller
- Año: 2025
- DOI: 10.48550/arXiv.2502.05392
- Clasificación temática: Contextualización externa, análisis conceptual
- Resumen: Discute retos en la detección de anomalías, enfatizando la contextualización externa, colaboración interdisciplinaria y escasez de datasets reales.
- Puntos clave:
 - Importancia del contexto del dominio
 - Crítica a la falta de benchmarks
 - No propone modelos específico
 - Contextualización es una etapa clave que está ausente en la mayoría de los estudios actuales, y plantea su necesidad como parte de un framework ideal.

Criterio	Valor	Observaciones
----------	-------	---------------

Autor	Müller	-
Año	2025	
Tipo de estudio	Análisis conceptual	El documento expone desafíos y perspectivas desde la industria, sin presentar validaciones empíricas directas.
Naturaleza	Teórico	
Incluye framework	No	Aunque se discute una visión estructurada de desafíos, el artículo no propone un framework formal ni implementable.
Framework diseño propio	No	No
Uso de datos reales	No	El documento es una reflexión teórica, no incluye experimentación con datasets, pero el artículo referencia casos reales
Validación en entornos reales	No	No se presenta ningún tipo de validación práctica ni simulación.
Revisión por pares	Sí	Publicado en Data-Centric AI, con proceso de revisión por pares.
Código disponible	No	No se ofrece ningún código o repositorio asociado. Referencia código de Ermshaus et al. [6] para experimentos de periodicidad. Sin embargo, no proporciona código nuevo ni un repositorio propio, y señala problemas con algunos métodos
Detección de anomalías	No	Se centra completamente en TAD, discutiendo desafíos (streaming, poblaciones, anomalías condicionales) y proponiendo definiciones formales (e.g., anomalías puntuales, métricas de evaluación). Aunque no implementa algoritmos (análisis de desafíos industriales, pero no describe, evalúa ni implementa ningún método de detección)
Predicción	No	No se aborda predicción de series ni escenarios futuros.
Almacenamiento	No	Se menciona la necesidad de infraestructura para gestionar datos y anomalías, pero no se propone ni diseña una solución específica.
Comparación entre eventos	Parcial	Discute dimensiones conceptuales relevantes y desafíos asociados a la comparación, sin implementación práctica, pero con un análisis argumentativo sobre la necesidad de esta función.
Considera contexto externo	Si	El artículo destaca anomalías condicionales (dependientes de información externa como festivos o ubicación) y propone retroalimentación humana para capturar contexto específico, similar a Sintel pero sin modelado específico.
Visualización avanzada	No	No se presentan herramientas ni técnicas de visualización como parte del documento.

6 : A Systematic Review of Anomaly Detection Using Machine and Deep Learning Techniques

- Autores: Sarfaraz Natha, Shahzad Ali, Abdul Hanan Abdullah, Noor Zaman Jhanjhi
- Año: 2022
- DOI: <https://doi.org/10.52584/QRJ.2001.11>
- Clasificación temática: Revisión sistemática, detección de anomalías
- Resumen: Revisión sistemática sobre detección de anomalías con ML y Deep Learning. Discute desafíos, pero sin experimentos ni métricas detalladas.
- Puntos clave:
 - Clasificación de anomalías: puntuales, colectivas, contextuales
 - Técnicas ML clásicas y deep learning
 - Problemas de interpretabilidad
 - Falta de validación en datos reales

Criterio	Valor	Observaciones
Autor	Natha	-
Año	2022	Confirmado en el encabezado del documento.
Tipo de estudio	Revisión sistemática	Se trata de una revisión estructurada de técnicas de detección de anomalías en ML/DL.
Naturaleza	Teórico	No implementa ni propone frameworks nuevos; se enfoca en analizar estudios existentes.
Incluye framework	No	No propone un framework nuevo, sino que revisa múltiples enfoques existentes.
Framework diseño propio	No	No aplica.
Uso de datos reales	No	Al ser una revisión, no realiza experimentos con datos reales.
Validación en entornos reales	No	No hay pruebas o validaciones propias; se limita a reportar lo que hacen otros estudios.
Revisión por pares	Sí	Publicado en Materials Today: Proceedings (Elsevier), con proceso de revisión por pares.
Código disponible	No	No se proporciona ningún código ni repositorio.
Detección de anomalías	Sí	Es el tema central de la revisión: técnicas de ML/DL para detectar anomalías.
Predicción	Parcial	Se mencionan técnicas con capacidades de predicción, pero no se analiza ni compara esta dimensión de forma estructurada o diferenciada.
Almacenamiento	No	No aborda temas de almacenamiento de anomalías o arquitectura de datos.
Comparación entre	No	No se identifican discusiones sobre comparación estructurada entre

eventos		anomalías en una serie temporal individual.
Considera contexto externo	No	No se abordan variables contextuales o externas; el análisis se limita a los algoritmos.
Visualización avanzada	No	El artículo incluye algunas figuras, pero no propone ni discute técnicas avanzadas de visualización.

7 : On the Nature and Types of Anomalies: A Review of Deviations in Data

- Autor: Ralph Foorthuis
- Año: 2021
- DOI: 10.1007/s41060-021-00265-1
- Clasificación temática: Revisión conceptual, tipología
- Resumen: Clasificación teórica de anomalías en cinco dimensiones. No incluye experimentos ni validación.
- Puntos clave:
 - Taxonomía conceptual: tipo de dato, cardinalidad, nivel, estructura, distribución
 - Sin datos ni casos de uso
 - Base conceptual sólida

Criterio	Valor	Observaciones
Autor	Foorthuis	-
Año	2021	Confirmado en el documento.
Tipo de estudio	Revisión conceptual - Revisión Teórica	El artículo clasifica y define distintos tipos de anomalías desde una perspectiva conceptual.
Naturaleza	Teórico	No implementa modelos ni evalúa resultados sobre datos reales.
Incluye framework	Sí	Se propone un marco conceptual de clasificación de anomalías, aunque no es un framework técnico implementable.
Framework diseño propio	Sí	El marco de clasificación es propio del autor, basado en análisis exhaustivo de literatura.
Uso de datos reales	No	No se usan datos, ni reales ni sintéticos. Es un análisis puramente teórico.
Validación en entornos reales	No	No aplica ningún tipo de validación práctica ni experimental.
Revisión por pares	Sí	Publicado en una revista revisada por pares.
Código disponible	No	No se incluye ningún repositorio ni código.
Detección de anomalías	No	No implementa métodos, pero el artículo clasifica los distintos tipos de anomalías que los métodos deben detectar. clasificar anomalías para AD, definiendo nueve tipos básicos y 63 subtipos que los métodos AD deben detectar. (presenta una tipología conceptual sobre tipos de anomalías, pero no propone ni analiza algoritmos de detección)
Predicción	No	No se analiza predicción como componente de los métodos revisados.

Almacenamiento	No	No se aborda el almacenamiento de anomalías.
Comparación entre eventos	No	No se propone ni discute el tema, se limita a definir tipos de anomalías y su taxonomía, incluyendo atributos
Considera contexto externo	No	Se menciona el concepto de “anomalías contextuales”, pero no se analiza ni profundiza como componente independiente o con aplicación práctica.
Visualización avanzada	No	No se incluyen herramientas o propuestas visuales para representar anomalías.

8 : On Data Efficiency of Univariate Time Series Anomaly Detection Models

- Autores: Wu Sun, Hui Li, Qingqing Liang, Xiaofeng Zou, Mei Chen, Yanhao Wang
- Año: 2024
- DOI: 10.1186/s40537-024-00940-7
- Clasificación temática: Optimización de modelos
- Resumen:
- FastUTS-AD: framework para detección eficiente en univariantes con solo el 9% de los datos.
- Puntos clave:
 - Evalúa 9 modelos en 8 datasets
 - Reducción de tiempo de entrenamiento
 - No aborda contextualización ni almacenamiento
 - **Comparación entre modelos, no entre anomalías detectadas dentro de la misma serie.**

Criterio	Valor	Observaciones
Autor	Sun et al.	-
Año	2024	Confirmado en portada.
Tipo de estudio	Estudio aplicado	Evalúa el rendimiento de modelos UTS-AD.
Naturaleza	Práctico	Se centra en eficiencia y evaluación de modelos con implementación propia.
Incluye framework	Sí	Se propone FastUTS-AD (Sun et al., 2024, p. 3), un framework para reducir el volumen de datos necesarios durante el entrenamiento.
Framework diseño propio	Sí	FastUTS-AD es un diseño original de los autores, con técnicas de muestreo, MCT y escalamiento (Sun et al., 2024, p. 18).
Uso de datos reales	Sí	Usa datasets como (SVDB, DAP, ECG, OPP, IOPS, SMD, YAHOO, MGAB), entre otros.
Validación en entornos reales	No	No hay implementación en producción ni sistemas en vivo.
Revisión por pares	Sí	Publicado en Machine Learning and Knowledge Extraction.
Código disponible	Sí	Disponible en GitHub:

		https://github.com/sunalbert/efficient-anomaly-detection
Detección de anomalías	Sí	Núcleo del trabajo. Se optimiza el entrenamiento sin comprometer la precisión.
Predicción	No	No aplica predicción futura, solo detección eficiente.
Almacenamiento	No	No se abordan mecanismos estructurados de almacenamiento.
Comparación entre eventos	No	No se evidencia ninguna comparación estructurada o semántica entre eventos anómalos.
Considera contexto externo	No	Solo se utilizan datos internos de cada serie.
Visualización avanzada	No	Se incluyen gráficas simples de resultados, pero no herramientas interactivas ni dashboards complejos.

9 : Lag Selection for Univariate Time Series Forecasting Using Deep Learning: An Empirical Study

- Autores: José Leites, Vitor Cerqueira, Carlos Soares
- Año: 2024
- DOI: 10.1007/978-3-031-73503-5_26 / arxiv.org/abs/2405.11237
- Clasificación temática: Predicción de anomalías, selección de rezagos
- Resumen: Estudio sobre selección de rezagos para predicción de series univariantes.
- Puntos clave:
 - Evalúa 9 métodos de selección de lags
 - Datasets: M1, M3, Tourism
 - No aborda detección ni contextualización

Criterio	Valor	Observaciones
Autor	Leites et al.	-
Año	2024	Confirmado en la portada.
Tipo de estudio	Estudio aplicado	Se evalúan modelos de forecasting aplicados en distintas configuraciones.
Naturaleza	Práctico	El estudio se enfoca en experimentos empíricos con modelos DL.
Incluye framework	No	No se propone un framework estructurado, solo una metodología experimental para selección de lags.
Framework diseño propio	No	Se emplean arquitecturas existentes (e.g., LSTM, CNN, Transformer).
Uso de datos reales	Sí	Se utilizan múltiples datasets reales (electricidad, tráfico, clima, etc.).
Validación en entornos reales	No	Todo el análisis se hace en entornos controlados o simulados, no en producción.
Revisión por pares	Sí	Publicado en el journal Neural Computing and Applications (Springer).

Código disponible	No	GitHub: https://github.com/jmleites/Lag_selection/
Detección de anomalías	No	El objetivo es forecasting, no detección de anomalías.
Predicción	Sí	Es el núcleo del estudio: predicción univariante con DL.
Almacenamiento	No	No se aborda almacenamiento estructurado de resultados.
Comparación entre eventos	No	No hay análisis posterior a la detección orientado a diferenciar o relacionar anomalías.
Considera contexto externo	No	El estudio es puramente univariante, sin incorporar variables externas.
Visualización avanzada	No	Presenta gráficos de error, pero sin visualización interactiva o dashboards.

10 : Context Discovery for Anomaly Detection

- Autores: Ece Calikus, Slawomir Nowaczyk, Onur Dikmen
- Año: 2025
- DOI: 10.1007/s41060-024-00586-x
- Clasificación temática: Contextualización, detección de anomalías
- Resumen:
- ConQuest: detección de anomalías contextuales mediante descubrimiento automático de múltiples contextos.
- Puntos clave:
 - Introduce MCAF
 - Optimización con NSGA-II
 - Evaluado en 25 datasets
 - Énfasis en interpretabilidad

Criterio	Valor	Observaciones
Autor	Calikus et al.	-
Año	2025	Confirmado en la portada del documento.
Tipo de estudio	Estudio aplicado	Se aplica un enfoque específico de descubrimiento de contexto a series temporales.
Naturaleza	Práctico	Se realiza implementación sobre datasets reales.
Incluye framework	Sí	Se propone un enfoque propio para descubrimiento de contexto en AD.
Framework diseño propio	Sí	El enfoque "Context Discovery for Anomaly Detection" es desarrollado por los autores.
Uso de datos reales	Sí	Se usan datasets reales como SWaT, WADI, y datos industriales.
Validación en entornos reales	No	Los experimentos se limitan a datasets de prueba, sin evidencia de pruebas en entornos de producción.

Revisión por pares	Sí	Documento presentado como preprint en arXiv y sometido a revisión.
Código disponible	No	No hay mención de un repositorio de código (e.g., GitHub) en los resultados web ni indicios de disponibilidad
Detección de anomalías	Sí	El objetivo es mejorar la detección mediante descubrimiento de contexto.
Predicción	No	El enfoque no busca predecir valores futuros, sino mejorar AD contextual.
Almacenamiento	No	No se incluye diseño de almacenamiento estructurado.
Comparación entre eventos	No	No se observa análisis comparativo entre anomalías dentro de una misma serie.
Considera contexto externo	No	Se centra explícitamente en el descubrimiento automático de contexto (factores latentes). Identifica automáticamente múltiples contextos relevantes para detectar anomalías, lo que implica considerar factores externos al dato aislado. No lo utiliza como contenido para enriquecer la serie
Visualización avanzada	No	Incluye algunos gráficos y visualizaciones estáticas, pero no menciona herramientas interactivas ni dashboards

11 : Neural Contextual Anomaly Detection for Time Series

- Autores: Chris U. Carmona, François-Xavier Aubet, Valentin Flunkert, Jan Gasthaus
- Año: 2022
- DOI: 10.48550/arXiv.2107.07702
- Clasificación temática: Detección de anomalías contextuales, deep learning
- Resumen:
- NCAD: método de redes neuronales para detectar anomalías contextuales mediante embeddings, hypersphere loss y data augmentation.
- Puntos clave:
 - Usa TCNs para embeddings de contexto
 - Combina ventanas de contexto y sospecha
 - Validación en SMAP, SMD, MSL, KPI, Yahoo
 - Mejora frente a otros modelos.

Criterio	Valor	Observaciones
Autor	Carmona et al.	-
Año	2022	Confirmado en el paper.
Tipo de estudio	Estudio aplicado	Se propone e implementa un modelo original.
Naturaleza	Práctico	Usa datasets reales y experimentación empírica.
Incluye framework	Sí	NCAD es un framework propio propuesto en el paper.
Framework diseño	Sí	NCAD es una arquitectura de red neuronal desarrollada por los

propio		autores.
Uso de datos reales	Sí	Se usa el dataset NAB, entre otros datos reales.
Validación en entornos reales	No	Las pruebas son en entornos controlados y benchmarks, no en producción.
Revisión por pares	Sí	Artículo revisado por pares en Proceedings of the 30th International Joint Conference on Artificial Intelligence (IJCAI).
Código disponible	Sí	Proporcionan repositorio en GitHub: https://github.com/nec-research/NCAD
Detección de anomalías	Sí	Es el objetivo central del modelo.
Predicción	Parcial	Usa un mecanismo de reconstrucción y predicción, pero solo para detectar anomalías
Almacenamiento	No	El modelo no incluye diseño de almacenamiento estructurado de resultados o eventos.
Comparación entre eventos	No	Aunque registra eventos, no analiza relaciones o comparaciones entre anomalías detectadas en una misma serie.
Considera contexto externo	Parcial	Incorpora variables contextuales internas a la serie o derivadas, pero no datos externos (e.g., clima, eventos).
Visualización avanzada	No	Se incluyen gráficos estándar de resultados, pero no dashboards ni visualización interactiva.

12: A Systematic Review of Anomaly Detection within High Dimensional and Multivariate Data

- Autores: Syahirah Suboh, Izzatdin Abdul Aziz, Shazlyn Milleana Shaharudin, Saidatul Akmar Ismail, Hairulnizam Mahdin
- Año: 2023
- DOI: <https://doi.org/10.30630/joiv.v7i1.1297>
- Clasificación temática: Revisión sistemática de detección de anomalías en datos multivariantes y de alta dimensionalidad
- Resumen: El estudio realiza una revisión sistemática de técnicas de detección de anomalías aplicadas a datos multivariantes y de alta dimensionalidad. Examina 22 artículos seleccionados mediante un proceso basado en PRISMA, clasificando los métodos en enfoques de reducción de dimensionalidad, aprendizaje automático y enfoques híbridos. Se destacan técnicas como PCA, DOBIN, Stray algorithm y DAE-KNN, así como métodos como ROBEM y OCP. El trabajo identifica desafíos clave, incluyendo la malinterpretación de anomalías, el alto costo computacional y la necesidad de distinguir entre valores extremos y verdaderas anomalías.
- **Puntos clave:**

- Presenta una clasificación temática clara de las técnicas existentes.
- Evalúa ventajas, desventajas y requerimientos computacionales de cada método.
- Propone que futuras investigaciones se enfoquen en interpretabilidad y evaluación real de las anomalías.
- Establece tres líneas de enfoque metodológico: reducción de dimensionalidad, machine learning y enfoques híbridos.
- El análisis incluye tanto algoritmos clásicos como recientes (ej. DOBIN, DAE-KNN).

Criterio	Valor	Observaciones
Autor	Suboh et al.	-
Año	2023	Confirmado en la portada del artículo.
Tipo de estudio	Revisión sistemática	Se trata de una revisión formal con criterios de búsqueda y selección explícitos.
Naturaleza	Teórico	No se presentan experimentos nuevos ni desarrollos propios.
Incluye framework	No	No se propone un nuevo framework estructurado; se enfoca en revisar técnicas existentes.
Framework diseño propio	No	No hay propuesta de un framework nuevo creado por los autores.
Uso de datos reales	No	Como revisión, analiza estudios que sí usan datos reales, pero el artículo en sí no realiza pruebas.
Validación en entornos reales	No	No aplica, al ser un estudio teórico sin ejecución experimental.
Revisión por pares	Sí	Publicado por una editorial académica y citado como revisión.
Código disponible	No	No hay código publicado por los autores.
Detección de anomalías	No	El paper enlista estudios, pero no describe directamente cómo se detectan anomalías, ni aporta un marco comparativo funcional sobre detección.
Predicción	Parcial	Menciona métodos predictivos como parte de la detección de anomalías.
Almacenamiento	No	El artículo no trata temas de almacenamiento de anomalías ni persistencia de datos.
Comparación entre eventos	No	No hay análisis o propuesta sobre comparaciones entre eventos anómalos.
Considera contexto externo	Parcial	Aunque se menciona contexto multivariado, no se analiza el uso explícito de variables contextuales externas (discute diferentes tipos de anomalías que pueden depender del contexto).
Visualización avanzada	No	Se presentan gráficos explicativos básicos, pero no se describe uso de herramientas visuales avanzadas.

13: A Review on Outlier/Anomaly Detection in Time Series Data

- Autores: Ane Blázquez-García, Ángel Conde, Usue Mori, José A. Lozano
- Año: 2020
- DOI: 10.1145/3444690
- Clasificación temática: Revisión sistemática, técnicas de detección de anomalías
- Resumen:
- Revisión exhaustiva con taxonomía por tipo de datos, tipo de outlier y tipo de método. Discute ventajas, limitaciones y presenta herramientas disponibles.
- Puntos clave:
 - Taxonomía de métodos y tipos de anomalías
 - Contexto: limpieza de datos o análisis de eventos
 - Repertorio de software
 - Se abordan outliers globales, contextuales y colectivos
 - Se discuten métricas de evaluación y uso de benchmarks
 - Se incluye una discusión amplia de software y librerías
 - Analisis teórico de comparacion entre anomalias, describe que metodos detectan anomalias colectivcas o contextuales, que metodos usan relaciones entre puntos dentro de la misma serie para decidir si es anomalo
 - Reconoce que hay anomalías que no pueden detectarse solo con los valores de la serie, porque necesitan contexto (por ejemplo, hora del día, época del año, lugar, etc.).

Criterio	Valor	Observaciones
Autor	Blázquez et al.	-
Año	2020	Confirmado en la portada del artículo.
Tipo de estudio	Revisión sistemática	Analiza 129 papers sobre detección de anomalías en series temporales.
Naturaleza	Teórico	No se implementan modelos, se hace análisis y clasificación.
Incluye framework	No	No se propone un framework funcional ni arquitectura operativa.
Framework diseño propio	No	Se presenta una taxonomía y categorías, pero no un framework técnico.
Uso de datos reales	No	No se presentan experimentos ni pruebas empíricas.
Validación en entornos reales	No	No aplica dado que no hay implementación.
Revisión por pares	Sí	Publicado en la revista Information Fusion.
Código disponible	No	No se menciona ni proporciona código fuente.
Detección de anomalías	Sí	El artículo analiza exhaustivamente técnicas de detección de anomalías.
Predicción	No	No se abordan modelos predictivos directamente.
Almacenamiento	No	No se discute almacenamiento estructurado ni persistencia.

Comparación entre eventos	Parcial	Se abordan algunos criterios que podrían usarse para comparar eventos, pero no se presenta una metodología o ejemplo aplicado.
Considera contexto externo	Parcial	Se menciona el contexto como factor para detectar anomalías contextuales, pero no se implementa ni ejemplifica detalladamente. Introducen el concepto de anomalías contextuales , que dependen del contexto (por ejemplo, un valor alto solo es anómalo en ciertos horarios o condiciones)
Visualización avanzada	No	No se presenta ni propone un componente visual especializado

14 : New Trends in Time Series Anomaly Detection

- Autores: Paul Boniol, Themis Palpanas
- Año: 2022
- DOI: N/A
- Clasificación temática: Revisión técnica de tendencias
- Resumen: Explora nuevas tendencias como Matrix Profile, Series2Graph, Isolation Forest. Reflexiona sobre escalabilidad e interpretabilidad.
- Puntos clave:
 - Técnicas para grandes volúmenes de datos
 - Matrix Profile, Series2Graph
 - Importancia de la interpretabilidad
 - Se enfoca principalmente en series univariantes, aunque sin dejar fuera multivariadas.
 - Señala que la evaluación de métodos sigue siendo un desafío abierto.

Criterio	Valor	Observaciones
Autor	Boniol et al.	-
Año	2023	Confirmado en el documento.
Tipo de estudio	Revisión temática	El artículo revisa las tendencias recientes y futuros retos en TAD.
Naturaleza	Teórico	No implementa ni valida modelos.
Incluye framework	No	No se propone un nuevo framework, se discuten tendencias y retos.
Framework diseño propio	No	No hay diseño estructurado propio, solo análisis general.
Uso de datos reales	No	No se utilizan datasets ni ejemplos empíricos.
Validación en entornos reales	No	No hay aplicación experimental ni simulación.
Revisión por pares	Sí	Publicado en ACM Computing Surveys.
Código disponible	No	No se proporciona código.
Detección de	Sí	Es el enfoque principal, analizado teóricamente en múltiples

anomalías		dimensiones.
Predicción	Parcial	Se discute la importancia de la predicción, pero sin propuesta concreta ni modelo.
Almacenamiento	No	Se menciona brevemente la persistencia como desafío, sin detalle ni soluciones.
Comparación entre eventos	Parcial	Aunque se identifican limitaciones que justifican la necesidad de comparar eventos, no se describe ni implementa tal comparación.
Considera contexto externo	Parcial	Se destacan los retos del contexto (variables externas, explicabilidad), pero no se proponen métodos.
Visualización avanzada	No	No se presentan técnicas visuales, apenas se menciona la necesidad de interpretabilidad.

15: A Systematic Literature Review of Time Series Methods Applied to Epidemic Prediction

- Autores: Apollinaire Batoure Bamana, Mahdi Shafiee Kamalabad, Daniel L. Oberski
- Año: 2024
- DOI: 10.1016/j.imu.2024.101571
- Clasificación temática: Revisión sistemática, predicción de epidemias
- Resumen:
- Revisión de 36 estudios sobre predicción de epidemias con series temporales. Resalta el foco en COVID-19 y la escasa cobertura en África.
 - Puntos clave:
 - Énfasis en COVID-19
 - Necesidad de validación en salud pública
 - Brecha en datos de África
 - Evalúa 26 estuarios entre 2000 y 2023
 - Destaca la necesidad de mejorar calidad de datos y evaluar modelos en entornos diversos.
 - Clasifica métodos en series temporales clásicas (ARIMA, SARIMA), redes neuronales (RNN, LSTM) y modelos híbridos.

Criterio	Valor	Observaciones
Autor	Batoure et al.	-
Año	2024	Confirmado en el encabezado del artículo.
Tipo de estudio	Revisión sistemática	Analiza estudios aplicados a predicción epidémica.
Naturaleza	Teórico	No implementa modelos propios ni propone nuevas soluciones.
Incluye framework	No	No propone ningún framework estructurado nuevo.

Framework diseño propio	No	No aplica.
Uso de datos reales	No	Aunque los estudios analizados pueden incluir datos reales, la revisión no trabaja directamente con ellos.
Validación en entornos reales	No	No valida ni implementa en entornos productivos.
Revisión por pares	Sí	Publicado en una revista académica con peer review.
Código disponible	No	No proporciona código fuente o repositorio.
Detección de anomalías	Parcial	Se analiza su importancia en el contexto de series temporales epidémicas, pero no se desarrolla en profundidad.
Predicción	Sí	Se analiza en profundidad el uso de métodos de predicción en series temporales aplicados a epidemias.
Almacenamiento	No	No discute aspectos relacionados al almacenamiento estructurado.
Comparación entre eventos	No	No se abordan ni conceptual ni prácticamente las comparaciones intra-serie.
Considera contexto externo	Parcial	Se discuten algunos elementos contextuales como políticas sanitarias o movilidad, pero no se desarrolla sistemáticamente como parte central del análisis.
Visualización avanzada	No	No se abordan técnicas de visualización avanzada.

16: Deep Learning for Time Series Anomaly Detection: A Survey

- Autores: Zahra Zamanzadeh Darban, Geoffrey I. Webb, Shirui Pan, Charu C. Aggarwal, Mahsa Salehi
- Año: 2023
- DOI: 10.1145/3691338
- Clasificación temática: Revisión sistemática, aprendizaje profundo
- Resumen:
- Revisión sobre DL para anomalías en series temporales, taxonomía basada en forecasting, reconstruction, representation, híbridos.
- Puntos clave:
 - Taxonomía detallada de enfoques DL
 - Modelos revisados: TranAD, InterFusion, DCT-GAN, etc.
 - Discusión de retos: interpretabilidad, evaluación
 - Señala la necesidad de **estandarizar benchmarks**.

Criterio	Valor	Observaciones
Autor	Zamanzadeh et al.	Confirmado en el documento.
Año	2022	Confirmado en la portada del artículo.

Tipo de estudio	Revisión sistemática	Revisión estructurada sobre técnicas de deep learning para detección de anomalías.
Naturaleza	Teórico	No se propone ni implementa ningún modelo nuevo.
Incluye framework	No	No se plantea un framework propio, aunque se resumen varios enfoques de la literatura.
Framework diseño propio	No	Solo se analizan modelos existentes.
Uso de datos reales	No	No hay experimentación directa ni datasets procesados.
Validación en entornos reales	No	El documento no incluye validación ni simulaciones.
Revisión por pares	Sí	Publicado en una revista académica indexada, con revisión por pares.
Código disponible	No	No se menciona código ni repositorios asociados.
Detección de anomalías	Sí	Es el tema central del paper: revisión de técnicas de DL para AD.
Predicción	Parcial	Se analizan modelos que realizan predicción como parte del proceso de detección.
Almacenamiento	No	No se discuten arquitecturas o métodos para almacenar anomalías.
Comparación entre eventos	No	No se describe ni conceptualmente ni empíricamente un mecanismo de comparación entre anomalías
Considera contexto externo	No	Se mencionan modelos que abordan anomalías contextuales, pero no se analiza en cómo se integra el contexto
Visualización avanzada	No	No se presentan ni describen herramientas de visualización.

17 Título: Dive into Time-Series Anomaly Detection: A Decade Review

- Autores: Paul Boniol, John Paparrizos, Themis Palpanas
- Año: 2024
- DOI: 10.1145/3657934.3657944
- Clasificación temática: Revisión sistemática, detección de anomalías
- Resumen:
- Revisión de una década en detección de anomalías en series temporales. Presenta taxonomía, discute retos como interpretabilidad, escalabilidad y evaluación.
- Puntos clave:
 - Clasificación: distancia, densidad, predicción, clustering
 - Discusión de retos y desafíos
 - Base conceptual para futuras investigaciones
 - Incluye una sección sobre tendencias emergentes y desafíos de implementación práctica.

Aunque menciona herramientas visuales y software asociado, no desarrolla visualizaciones propias.

Criterio	Valor	Observaciones
Autor	Boniol et al.	Confirmado en la portada y primeras páginas del documento.
Año	2024	Claramente indicado en el documento.
Tipo de estudio	Revisión sistemática	Se analiza una década de publicaciones, siguiendo un enfoque sistemático y categorizado.
Naturaleza	Teórico	No se implementan algoritmos ni se realizan experimentos propios; se limita al análisis exhaustivo de literatura.
Incluye framework	No	No se propone un framework original; se clasifican y discuten modelos existentes.
Framework diseño propio	No	No hay ningún diseño propuesto ni arquitectura original.
Uso de datos reales	No	El artículo no implementa pruebas ni usa datasets directamente.
Validación en entornos reales	No	No hay validación empírica o simulaciones presentadas.
Revisión por pares	Sí	El paper fue publicado en Information Fusion, una revista revisada por pares.
Código disponible	No	No se ofrece código propio; aunque se mencionan repositorios de terceros, no es parte de la contribución del artículo.
Detección de anomalías	Sí	Es el tema central; se hace un análisis exhaustivo de técnicas TDAD.
Predicción	No	Se discuten métodos que incluyen predicción como componente, pero no se implementan ni se analiza en profundidad el proceso predictivo.
Almacenamiento	No	No se aborda el tema del almacenamiento estructurado de anomalías.
Comparación entre eventos	No	No incluye análisis o propuesta para comparación de eventos anómalos dentro de la misma serie.
Considera contexto externo	Parcial	Se mencionan algunas técnicas que incorporan contexto externo (e.g., contextual anomalies), pero el artículo no desarrolla esta perspectiva con profundidad suficiente como para considerarlo un enfoque claro.
Visualización avanzada	No	

18 : Time Series Forecasting using Artificial Neural Networks Methodologies: A Systematic Review

- Autor: Ahmed Tealab
- Año: 2018
- DOI: 10.1016/j.fcij.2018.10.003
- Clasificación temática: Predicción, redes neuronales, modelos híbridos
- Resumen:

- Revisión de 17 estudios sobre predicción con ANN, destaca necesidad de integrar ARMA y promedios móviles.
- Puntos clave:
 - Crítica a la falta de innovación
 - Revisión de 17 estudios (2006-2016)
 - Propuesta de modelos más robustos
 - Se enfoca en modelos de predicción, no en detección de anomalías.
 - Propone desarrollar modelos híbridos con series estadísticas tradicionales (ARMA, moving average)

Criterio	Valor	Observaciones
Autor	Tealab	Confirmado.
Año	2018	Confirmado en el título y documento.
Tipo de estudio	Revisión sistemática	Basado en múltiples fuentes bibliográficas, con estructura metodológica.
Naturaleza	Teórico	No realiza implementación experimental.
Incluye framework	No	No propone una arquitectura unificada ni sistema funcional.
Framework diseño propio	No	No se presenta ninguna propuesta propia de diseño.
Uso de datos reales	No	No se incluyen experimentos ni pruebas sobre datos.
Validación en entornos reales	No	No aplica validaciones experimentales.
Revisión por pares	Sí	Publicado en revista científica, revisada por pares.
Código disponible	No	No proporciona código, ya que no se desarrolló software o modelos propios.
Detección de anomalías	Parcial	Aunque menciona la detección de anomalías como aplicación de las redes neuronales, no es el foco central ni se desarrolla en profundidad.
Predicción	Sí	El artículo trata específicamente sobre predicción de series temporales usando redes neuronales.
Almacenamiento	No	No se trata ningún mecanismo de almacenamiento.
Comparación entre eventos	No	Aunque útil en predicción, no hay discusión sobre eventos anómalos ni su comparación.
Considera contexto externo	No	No incluye análisis de variables externas.
Visualización avanzada	No	No se reportan herramientas ni técnicas específicas de visualización.

19: Enhancing Time Series Anomaly Detection: A Knowledge Distillation Approach with Image Transformation

- Autores: Haiwoong Park, Hyeryung Jang
- Año: 2024
- DOI: <https://doi.org/10.3390/s24248169>
- Clasificación temática: Detección de anomalías, contextualización, conocimiento distillation, transformación de datos, imágenes
- Resumen: Este estudio propone un framework novedoso para la detección de anomalías en series temporales, que transforma los datos en imágenes mediante Gramian Angular Fields (GAF) y utiliza técnicas avanzadas de detección de anomalías en imágenes basadas en knowledge distillation (RD y EAD). El enfoque permite una mayor eficiencia computacional y mejora la precisión en datasets como SWaT, UCR y NAB, demostrando una capacidad robusta para manejar datos con ruido, valores atípicos y secuencias no lineales. Se destaca la capacidad de generar mapas de anomalías explicativos, la segmentación por ciclos para capturar patrones estables y la integración modular para adaptar el sistema a diferentes tipos de datos.
- Puntos clave:
 - Introduce un método de transformación de series a imágenes (GAF) para preservar relaciones temporales.
 - Utiliza knowledge distillation (Reverse Distillation y EfficientAD) para generar mapas de anomalías.
 - Mejora la eficiencia y precisión en datasets reales, alcanzando hasta 99% de F1-score en algunos casos.
 - Segmenta series por ciclos para mejorar la formación de patrones normales.
 - Capaz de detectar anomalías puntuales, contextuales y colectivas.
 - Aborda la limitación de datos anómalos escasos mediante procesamiento y transformación.
 - Integra técnicas de aprendizaje no supervisado en un pipeline modular.
 - Propone la combinación de modelos ligeros (EAD) con métodos más complejos (RD) según las necesidades del caso.
 - Identifica la necesidad de mejorar la relación entre imágenes transformadas y la secuencia original como futura línea de investigación.
 - Detecta anomalías puntuales, colectivas y contextuales.
 - Reporta resultados con F1-score superiores al 95% en múltiples datasets (SWaT, UCR, NAB).

Criterio	Valor	Observaciones
Autor	Park et al.	Confirmado en el documento.
Año	2024	Aparece en el encabezado del paper.
Tipo de estudio	Estudio aplicado	Se implementa un nuevo enfoque y se evalúa experimentalmente.
Naturaleza	Práctico	Desarrolla y prueba una arquitectura propia en datasets reales.
Incluye framework	Sí	Propone un enfoque de conocimiento que transforma datos en imágenes.
Framework diseño propio	Sí	El modelo propuesto y la estrategia de entrenamiento son originales.
Uso de datos reales	Sí	Secure Water Treatment (SWaT) , que es un dataset de un sistema real

Validación en entornos reales	Parcial	Aunque se usan datos reales, la validación es experimental, no en sistemas de producción. (usa entornos controlados)
Revisión por pares	Sí	Publicado en IEEE Access, revista con revisión por pares.
Código disponible	No	No
Detección de anomalías	Sí	
Predicción	Parcial	El enfoque se basa en reconstrucción de señales.
Almacenamiento	No	No se aborda la persistencia o gestión estructurada de resultados.
Comparación entre eventos	No	Se enfoca en detección precisa, pero no compara anomalías entre sí ni explora su relación.
Considera contexto externo	No	No incorpora variables adicionales al comportamiento de la serie.
Visualización avanzada	No	Las transformaciones a imagen son para el análisis, no para la visualización humana)

20 : TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data

- Autores: Shreshth Tuli, Giuliano Casale, Nicholas R. Jennings
- Año: 2022
- DOI: arXiv:2201.07284
- Clasificación temática: Detección de anomalías, multivariantes, deep learning
- Resumen:
- TranAD: modelo basado en Transformer, combina auto-condicionamiento y adversarial training, mejora F1-score 17%, reduce tiempo de entrenamiento 99%.
- Puntos clave:
 - Modelo Transformer con auto-condicionamiento
 - Comparación con Isolation Forest, LSTM-VAE
 - Ahorro de tiempo y mejora en precisión

Criterio	Valor	Observaciones
Autor	Shreshth Tuli et al.	
Año	2022	
Tipo de estudio	Estudio aplicado	Se implementa un nuevo enfoque y se evalúa experimentalmente.
Naturaleza	Práctico	Desarrolla y prueba una arquitectura propia en datasets reales.
Incluye framework	Sí	Se propone una arquitectura completa basada en Transformers (TranAD) para detección de anomalías, incluyendo un proceso de entrenamiento adversarial y preprocesamiento.

Framework diseño propio	Sí	TranAD es un diseño original de los autores, propuesto y detallado como contribución principal del estudio.
Uso de datos reales	Sí	Se usan múltiples datasets reales como NAB, SWaT, WADI, y SMD.
Validación en entornos reales	No	Aunque se usan datasets reales, no se valida el modelo en entornos de producción.
Revisión por pares	Sí	Publicado en Proceedings of the 2022 SIAM International Conference on Data Mining (SDM), revisado por pares.
Código disponible	Sí	Repositorio público disponible en GitHub: https://github.com/imperial-gore/TranAD
Detección de anomalías	Sí	
Predicción	No	Usa un mecanismo de reconstrucción y predicción, pero solo para detectar anomalías, no para forecasting explícito.
Almacenamiento	No	No aborda estructuras ni modelos de almacenamiento.
Comparación entre eventos	No	Aunque la reconstrucción temporal puede sugerir diferencias, no se formaliza ninguna comparación intra-serie entre anomalías detectadas.
Considera contexto externo	No	Todo el enfoque se limita a los datos incluidos en la serie multivariable, sin usar contexto externo adicional.
Visualización avanzada	No	Se presentan gráficos de rendimiento y visualizaciones básicas, sin propuestas de herramientas interactivas.

21 : Deep Learning for Anomaly Detection: A Survey

- **Autores:** Raghavendra Chalapathy, Sanjay Chawla
- **Año:** 2019
- **DOI:** 10.48550/arXiv.1901.03407
- **Clasificación temática:** Revisión sistemática – Aprendizaje profundo aplicado a detección de anomalías
- **Resumen:** Este artículo presenta una revisión sistemática de las técnicas de aprendizaje profundo aplicadas a la detección de anomalías. Se abordan los desafíos únicos que enfrentan los modelos de deep learning en este dominio, tales como la escasez de datos etiquetados y la necesidad de modelos no supervisados. La revisión clasifica las técnicas de detección de anomalías en base al tipo de modelo (autoencoders, redes generativas, etc.), su nivel de supervisión (supervisado, semi-supervisado, no supervisado) y el tipo de datos. Se discuten además las aplicaciones en diversas áreas como seguridad, medicina y mantenimiento predictivo.
- **Puntos clave:**
 - Enfoca la revisión exclusivamente en métodos de aprendizaje profundo.
 - Clasifica los enfoques por tipo de supervisión y arquitectura.
 - Discute aplicaciones en dominios sensibles como salud, industria y seguridad.
 - Resalta los desafíos actuales, como la escasez de datos y la necesidad de interpretabilidad.
 - Revisión de técnicas de deep learning aplicadas a detección de anomalías.
 - Discute retos: escasez de etiquetas, interpretabilidad y escalabilidad.

Criterio	Valor	Observaciones
Autor	Chalapathy, R., & Chawla, S.	-
Año	2019	Confirmado en la portada del artículo.
Tipo de estudio	Revisión temática	El artículo revisa distintas arquitecturas deep learning aplicadas a la detección de anomalías.
Naturaleza	Teórico	No implementa modelos ni presenta resultados experimentales propios.
Incluye framework	No	No se propone un framework estructurado, sino que se clasifican enfoques existentes.
Framework diseño propio	No	No hay aportes metodológicos nuevos; se resumen modelos existentes.
Uso de datos reales	No	No hay experimentación con datos. Se citan estudios que los utilizan.
Validación en entornos reales	No	No aplica. Solo se revisan estudios existentes.
Revisión por pares	Sí	Publicado en la revista IEEE Access, revisada por pares.
Código disponible	No	No se ofrece código ni repositorio asociado.
Detección de anomalías	Sí	Revisión profunda de técnicas de DL para TAD.
Predicción	Parcial	Menciona técnicas que pueden implicar predicción, como autoencoders, pero no se desarrolla ni profundiza como un eje principal.
Almacenamiento	No	No se menciona ningún enfoque de almacenamiento estructurado.
Comparación entre eventos	No	Se centra en detección y clasificación general de anomalías, pero no aborda relaciones o comparaciones entre eventos.
Considera contexto externo	No	Algunos modelos descritos, como context-aware, mencionan esta posibilidad, pero el artículo no la aborda en profundidad.
Visualización avanzada	No	No se tratan aspectos de visualización como parte clave de la revisión.

22: Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy

- Autores: Jiehui Xu, Haixu Wu, Jianmin Wang, Mingsheng Long
- Año: 2022
- DOI: <https://doi.org/10.48550/arXiv.2110.02642>
- Clasificación Temática:
- Detección de anomalías, aprendizaje profundo, transformers, series temporales

- Resumen:
- El artículo propone Anomaly Transformer, un modelo innovador para la detección no supervisada de anomalías en series temporales. El enfoque se centra en la Discrepancia de Asociación (Association Discrepancy), la cual mide la diferencia entre las asociaciones de puntos anómalos y normales mediante una atención de doble rama: prior-association y series-association. La técnica incorpora un mecanismo de Anomaly-Attention y una estrategia de entrenamiento minimax para maximizar la discriminación entre puntos normales y anómalos. El modelo es validado en seis benchmarks y supera significativamente a modelos previos como LSTM-VAE, THOC y BeatGAN, destacándose por su robustez en distintos tipos de anomalías (puntuales, contextuales, de patrones) y por lograr una mejor colaboración entre reconstrucción y asociación para detectar anomalías.
- Puntos Clave:
 - Introduce el concepto de Association Discrepancy como criterio principal de anomalía.
 - Implementa el mecanismo Anomaly-Attention con dos ramas para prior-association (atención cercana) y series-association (atención global).
 - Utiliza una estrategia minimax para maximizar la distinción entre datos normales y anómalos.
 - Logra SOTA (State of the Art) en seis benchmarks (SMD, PSM, MSL, SMAP, SWaT, NeurIPS-TS).
 - Destaca la importancia de la adaptabilidad del parámetro σ para modelar asociaciones en diferentes patrones de series.
 - Publicado en ICLR 2022.

Criterio	Valor	Observación
Autor	Xu et al.	Confirmado.
Año	2022	Confirmado.
Tipo de estudio	Estudio aplicado	Presenta un modelo aplicado a datasets reales.
Naturaleza	Práctico	Implementación técnica detallada y validada.
Incluye framework	Sí	El Anomaly Transformer es un framework completo de detección.
Framework diseño propio	Sí	Es una propuesta original de los autores.
Uso de datos reales	Sí	Evalúan el modelo con múltiples datasets reales (p. ej., SMD, MSL, SMAP).
Validación en entornos reales	No	Validación experimental, pero no en producción.
Revisión por pares	Sí	Publicado en ICLR 2022, con revisión por pares.
Código disponible	Sí	El código está disponible en GitHub (enlace directo).
Detección de anomalías	Sí	Es el objetivo principal. Introduce una métrica basada en association discrepancy.
Predicción	Parcial	No se realiza forecast, sino reconstrucción para detección.
Almacenamiento	No	No se abordan estructuras de almacenamiento.

Comparación entre eventos	No	Utiliza atención para detectar desviaciones dentro de la serie, pero no compara eventos anómalos entre sí, ni analiza relaciones entre múltiples anomalías.
Considera contexto externo	No	No usa variables externas ni información contextual explícita.
Visualización avanzada	No	Usa algunas visualizaciones para análisis de resultados, pero no se considera un enfoque de visualización.

23 : TadGAN: Time Series Anomaly Detection Using Generative Adversarial Networks

- Autores: Alexander Geiger, Dongyu Liu, Sarah Alnegheimish, Alfredo Cuesta-Infante, Kalyan Veeramachaneni
- Año: 2020
- DOI: <https://doi.org/10.48550/arXiv.2009.07769>
- Clasificación temática: Detección de anomalías, series temporales, aprendizaje profundo, GANs
- Resumen:
- El artículo presenta TadGAN, un marco de detección de anomalías en series temporales basado en Generative Adversarial Networks (GANs). Utiliza redes neuronales recurrentes LSTM como base para el generador y el discriminador, con una arquitectura de aprendizaje no supervisado que aplica una pérdida de consistencia cíclica para garantizar la reconstrucción efectiva de datos normales. El enfoque permite detectar anomalías en entornos donde los datos etiquetados son escasos o inexistentes. El estudio evalúa TadGAN en 11 conjuntos de datos multivariantes y univariantes (NASA, Yahoo, etc.), demostrando mejoras en F1-score frente a ocho métodos de referencia.

Sin embargo, TadGAN se centra en la reconstrucción basada en GANs, no considera la contextualización externa, no aborda el almacenamiento estructurado de anomalías ni la visualización avanzada, y depende de una cuidadosa selección de hiperparámetros y preprocesamiento.

- Puntos clave
 - Introduce GANs cíclicos para detectar anomalías en series temporales no supervisadas.
 - Utiliza redes LSTM como base para generador y discriminador.
 - Entrena el modelo con pérdida de consistencia cíclica.
 - Demuestra resultados competitivos en 11 datasets públicos.
 - Limitaciones:
 - Sensibilidad a hiperparámetros.
 - No contextualiza con datos externos.
 - No aborda almacenamiento ni visualización.
 - Dependencia de preprocesamiento y configuración de ventanas.

Campo	Valor	Justificación
Autor	Geiger et al.	Confirmado en el título del documento.

Año	2020	Confirmado en el encabezado del paper.
Tipo de estudio	Estudio aplicado	Se propone y evalúa un nuevo modelo aplicado a conjuntos de datos reales.
Naturaleza	Práctico	Implementa un modelo GAN para AD con experimentos sobre datasets reales.
Incluye framework	Sí	Se introduce TadGAN, una arquitectura basada en GAN para detección de anomalías en series temporales.
Framework diseño propio	Sí	TadGAN es un modelo propuesto por los autores como una arquitectura nueva.
Uso de datos reales	Sí	Se usan datasets como ECG5000, NAB y KPI, entre otros, para evaluar el modelo.
Validación en entornos reales	No	No se reporta uso en producción ni validación con expertos o despliegue en sistemas reales.
Revisión por pares	Sí	Publicado como artículo revisado por pares en la conferencia ICML 2020 Workshop.
Código disponible	Sí	Repositorio oficial disponible en GitHub: https://github.com/salesforce/TadGAN
Detección de anomalías	Sí	Es el objetivo principal del paper: detectar anomalías en series temporales.
Predicción	Parcial	El modelo reconstruye series para comparar, pero no genera predicciones explícitas a futuro.
Almacenamiento	No	No se discuten ni proponen estructuras de almacenamiento de datos anómalos.
Comparación entre eventos	No	El modelo reconstruye secuencias para detectar anomalías, pero no contempla mecanismos de comparación o agrupamiento de eventos anómalos.
Considera contexto externo	No	No se menciona el uso de variables exógenas ni integración de contexto externo.
Visualización avanzada	No	Incluye visualizaciones de resultados, pero no se propone un módulo de visualización ni herramientas interactivas.

24 : Reward Once, Penalize Once: Rectifying Time Series Anomaly Detection

- Autores: Keval Doshi, Shatha Abudalou, Yasin Yilmaz
- Año: 2022
- DOI: 10.1109/IJCNN55064.2022.9891913
- Clasificación Temática:
- Detección de anomalías, series temporales, evaluación de rendimiento, transformers
- Resumen:
- Este paper identifica y critica una limitación fundamental en la evaluación tradicional de modelos de detección de anomalías en series temporales, donde un ajuste en la métrica

(Adjusted Instance-based F1) puede generar resultados artificialmente inflados, incluso superando a los SOTA con un modelo aleatorio. Para abordar este problema, los autores proponen una nueva métrica llamada Sequence Precision Delay (SPD) que evalúa la detección de secuencias anómalas considerando la puntualidad y precisión de la alarma. Además, presentan TiSAT, un nuevo modelo basado en Transformer optimizado para la detección de anomalías en series temporales, que incorpora atención probabilística (ProbSparse) para manejar dependencias de largo alcance de manera eficiente. El modelo supera significativamente a métodos tradicionales y de última generación en cinco benchmarks.

- Puntos Clave:
 - Identifica el sesgo en la métrica F1 ajustada utilizada en varios modelos SOTA.
 - Propone la métrica Sequence Precision Delay (SPD) para medir la precisión y puntualidad de las detecciones.
 - Presenta el modelo TiSAT, un Transformer optimizado con atención dispersa (ProbSparse) y un marco de acumulación de evidencia para decisiones más robustas.
 - Evalúa en cinco benchmarks (SMD, PSM, MSL, SMAP, SWaT), mostrando mejoras sustanciales sobre métodos como LSTM, ARIMA, IsolationForest, etc.
 - Aporta un análisis teórico de la tasa de falsas alarmas y un procedimiento para definir umbrales de detección basados en garantías estadísticas.

Criterio	Valor	Observaciones
Autor	Doshi et al.	-
Año	2022	Confirmado en el documento
Tipo de estudio	Estudio técnico experimental	Presenta una propuesta metodológica y la compara con métodos existentes
Naturaleza	Práctico	Implementa, evalúa y compara un nuevo método
Incluye framework	Sí	Proponen una nueva estrategia de evaluación de métricas para AD
Framework diseño propio	Sí	La propuesta Reward Once, Penalize Once (ROPO) es original
Uso de datos reales	Sí	Evalúan sobre múltiples datasets estándar
Validación en entornos reales	No	No hay evidencia de pruebas en entornos productivos
Revisión por pares	Sí	Publicado y referenciado en plataformas científicas
Código disponible	Sí	El paper proporciona enlace al código fuente para reproducibilidad
Detección de anomalías	Sí	Su objetivo principal es mejorar la evaluación de modelos de AD
Predicción	No	No implementa técnicas predictivas ni lo aborda conceptualmente
Almacenamiento	No	No se diseña infraestructura de almacenamiento
Comparación entre eventos	No	Critica métricas de evaluación, propone ajustes para detección puntual. No realiza comparación semántica o estructurada entre

		eventos anómalos.
Considera contexto externo	No	Solo trabaja con datos de entrada y salida, sin variables exógenas
Visualización avanzada	Parcial	Utiliza gráficas estándar, sin herramientas interactivas ni enfoque visual detallado, sin embargo usa visualizaciones comparativas que destacan fallos de métricas.

25 : PeFAD: A Parameter-Efficient Federated Framework for Time Series Anomaly Detection

- Autores: Ronghui Xu, Hao Miao, Senzhang Wang, Philip S. Yu, Jianxin Wang
- Año: 2024
- DOI: <https://doi.org/10.48550/arXiv.2406.02318>
- Clasificación temática:
- Detección de anomalías, series temporales, aprendizaje federado, eficiencia de parámetros, privacidad
- Resumen:
- PeFAD es un framework federado para detección de anomalías en series temporales que permite a los clientes ajustar solo una fracción de los parámetros del modelo (cabezas PLM), reduciendo la comunicación y protegiendo la privacidad. Integra enmascarado adaptativo de anomalías y generación de datos sintéticos para entrenar modelos sin compartir datos reales. Evalúa su rendimiento en datasets reales como SMD, PSM, SWaT y MSL, logrando una mejora de hasta 28.74% respecto a enfoques federados tradicionales.
- Puntos clave:
 - Framework federado que preserva privacidad y reduce costos de comunicación.
 - Uso de modelos de lenguaje preentrenados (PLM) para generalizar patrones.
 - Enmascarado adaptativo de anomalías (ADMS) y generación de datos sintéticos (PPDS).
 - Mejora del rendimiento y adaptabilidad a diferentes tipos de anomalías

Criterio	Valor	Observaciones
Autor	Xu et al	
Año	2024	
Tipo de estudio	Estudio aplicado	Presenta y valida un framework federado para detección de anomalías.
Naturaleza	Práctico	Implementa un sistema completo y lo prueba en datasets reales.
Incluye framework	Sí	Propone PeFAD, un marco federado para la detección de anomalías en series temporales.
Framework diseño propio	Sí	PeFAD es una propuesta original de los autores, desarrollada en el artículo.
Uso de datos reales	Sí	Utiliza datasets reales como SMAP y MSL para evaluar el rendimiento.
Validación en entornos reales	No	Los experimentos se limitan a entornos de evaluación académicos (datasets públicos), sin pruebas en producción.

Revisión por pares	Sí	Publicado y referenciado en plataformas científicas
Código disponible	Sí	Se menciona un repositorio GitHub con el código fuente del framework.
Detección de anomalías	Sí	
Predicción	No	El enfoque no incluye predicción de valores futuros.
Almacenamiento	No	No se diseña infraestructura de almacenamiento
Comparación entre eventos	No	Propone un framework federado para detección eficiente, pero no aborda el análisis relacional entre anomalías.
Considera contexto externo	Parcial	El enfoque federado toma en cuenta la heterogeneidad entre clientes, lo que puede interpretarse como contexto parcial.
Visualización avanzada	No	

26 : MTV: Visual Analytics for Detecting, Investigating, and Annotating Anomalies in Multivariate Time Series

- Autores: Dongyu Liu, Sarah Alnegheimish, Alexandra ZYTEK, Kalyan Veeramachaneni
- Año: 2021
- DOI: <https://doi.org/10.48550/arXiv.2112.05734>
- Clasificación temática: Visualización de anomalías, detección de anomalías, colaboración humano-IA
- Resumen:
- El artículo presenta MTV, un sistema de análisis visual interactivo para la detección, investigación y anotación colaborativa de anomalías en series temporales multivariantes. MTV integra un pipeline de aprendizaje automático para detección de anomalías, visualizaciones interactivas personalizadas, y flujos de trabajo colaborativos entre expertos. La herramienta permite la exploración multi-faceta de datos temporales, soporta anotaciones in-situ, y retroalimenta los modelos de machine learning con comentarios de los usuarios. El estudio incluye colaboraciones con expertos de la industria aeroespacial y energética, demostrando la efectividad de MTV para análisis complejos de anomalías.
- Puntos clave:
 - Presenta un sistema de visualización interactiva para detectar y anotar anomalías en series temporales.
 - Soporta colaboración entre expertos mediante anotaciones y comentarios sobre eventos anómalos.
 - Introduce un algoritmo de shape-matching para buscar patrones similares.
 - Implementa un pipeline de ML con ARIMA, LSTM y TadGAN para detección sin etiquetas.
 - Evaluado en casos de estudio reales con datos de telemetría de satélites y datos financieros.
 - Mejora la eficiencia del análisis y reduce falsos positivos mediante retroalimentación de usuarios.
 - Facilita la comprensión de datos complejos con visualizaciones multigranulares y multi-escala.

Criterio	Valor	Observaciones
Autor	Liu et al.	
Año	2021	
Tipo de estudio	Estudio aplicado	Se desarrolla e implementa una herramienta visual para detección y análisis de anomalías en series temporales multivariantes.
Naturaleza	Práctico	Incluye desarrollo, implementación y evaluación de un sistema (MTV) sobre datasets reales.
Incluye framework	Sí	MTV es una propuesta estructurada de sistema visual, con componentes para detección, visualización, anotación e investigación de anomalías.
Framework diseño propio	Sí	El framework MTV es diseñado por los autores y combina analítica visual con modelos de predicción para anomalías.
Uso de datos reales	Sí	Evalúa el sistema usando datasets reales como ECG y sensores industriales.
Validación en entornos reales	Parcial	Se prueba en entornos controlados, no se prueba en entornos de producción o industriales reales.
Revisión por pares	Sí	Publicado en IEEE Transactions on Visualization and Computer Graphics.
Código disponible	No	
Detección de anomalías	Sí	Incorpora técnicas automáticas de detección, como STL y AutoEncode
Predicción	Parcial	El sistema incluye predicción para facilitar la detección, pero no es su objetivo principal.
Almacenamiento	Parcial	El sistema permite guardar anotaciones, eventos y marcas dentro del entorno visual, pero no propone un modelo formal de almacenamiento estructurado ni un esquema persistente para consulta futura.
Comparación entre eventos	Si	El sistema permite comparar visualmente comportamientos pasados y actuales dentro de la misma serie.
Considera contexto externo	Parcial	El sistema permite al usuario añadir etiquetas y comentarios manuales que aportan contexto, pero no incorpora fuentes externas automáticamente.
Visualización avanzada	Si	Incluye herramientas interactivas de visualización, zoom, anotación, gráficos de componentes, y vistas múltiples.